

Faculdade de Ciências e Tecnologias da Universidade de Coimbra



Departamento de engenharia informática

Trabalho Prático 2 (The Evolution of Lunar Lander) –
Fundamentos de Inteligência Artificial (FIA)

RELATÓRIO

Professor: Eliezer Silva

Autores:

Lorando Cá - 2022195277 - uc2022195277@student.uc.pt - PL6

Pedro Ferreira - 2023112367 - uc2023112367@student.uc.pt - PL6

Raphael Kuwae - 2023222627 - uc2023222627@student.uc.pt - PL7

Introdução

O Sistema do Lunar Lander consiste em controlar uma nave espacial com objetivo de realizar uma aterrissagem segura em uma plataforma na superfície lunar, tendo em conta variáveis como posição, velocidade e orientação.

Neste trabalho, foi adotada uma abordagem de neuroevolução, onde os parâmetros de uma rede neuronal são otimizados através de um Algoritmo Evolucionário (AE). Essa abordagem depende de operadores evolutivos como seleção, crossover e mutação.

O objetivo dessa meta foi desenvolver e analisar um algoritmo capaz de evoluir agentes que aterrissem com sucesso em ambientes sem vento, implementado os principais componentes do AE e definindo uma função objetivo adequada.

Índice	Variável	Descrição
0	x	Posição horizontal da nave em relação ao centro (plataforma de aterragem). Negativa à esquerda; positiva à direita.
1	y	Posição vertical da nave em relação ao solo.
2	vx	Velocidade horizontal da nave. Negativa quando se move para a esquerda; positiva quando se move para a direita.
3	vy	Velocidade vertical da nave. Negativa quando desce; positiva quando sobe.
4	theta	Orientação da nave. Negativa quando está inclinada para a direita; positiva quando está inclinada para a esquerda.
5	vtheta	Velocidade angular (mudança no ângulo). Negativa quando roda no sentido horário; positiva quando roda no sentido anti-horário.
6	left_leg	Booleano (1 ou 0): indica se a perna esquerda está em contacto com o solo.
7	right_leg	Booleano (1 ou 0): indica se a perna direita está em contacto com o solo.

Tabela 1: Espaço de observações

Representação do problema

Cada indivíduo da população representa um controlador da nave, sendo composto por:

- Genótipo: vetor de números reais (pesos da rede neuronal)

- Fenótipo: comportamento da rede no ambiente

A arquitetura da rede é definida pelo tuplo SHAPE = (8, 12, 2), significando:

- 8 entradas: correspondentes às 8 variáveis de observação do ambiente (posição x, y; velocidade vx, vy; ângulo theta, velocidade angular vtheta; e contacto das pernas esquerda e direita);
- 12 neurônios na camada oculta: escolhidos por representarem um bom compromisso entre capacidade expressiva e eficiência computacional;
- 2 saídas: representando os comandos dos motores principal e secundários.

Função objetivo

A função objetivo é um componente do AE que busca evoluir na direção do comportamento desejado. A função objetivo implementada avalia a qualidade do aterrisagem com base na última observação do episódio, penalizando três componentes:

- Penalidade de distância horizontal: penaliza o afastamento horizontal da nave ($|x|$) em relação ao centro da plataforma, com peso 100, por ser o critério mais relevante para uma aterragem precisa;
- Penalidade de velocidade vertical: penaliza a velocidade vertical residual ($|vy|$), com peso 100, pois uma aterragem suave requer velocidade de descida próxima de zero;
- Penalidade de ângulo: penaliza a inclinação ($|theta|$), com peso 50, pois a nave deve aterrar verticalmente;
- Penalidade de contacto das pernas: penaliza a ausência de contacto de ambas as pernas com o solo, com peso 50, incentivando a nave a pousar com as duas pernas simultaneamente.

A fórmula adotada é: **fitness** = $-100 \cdot |x| - 100 \cdot |vy| - 50 \cdot |theta| - 50 \cdot [(1 - \text{left_leg})^2 + (1 - \text{right_leg})^2]$, onde cada componente penaliza o desvio em relação ao comportamento ideal.

Esta formulação produz valores tipicamente negativos, sendo 0 o valor ideal (nave na plataforma, sem velocidade, sem inclinação e com ambas as pernas em contacto). A avaliação é calculada sobre a média das últimas 10 observações do episódio, em vez da última observação isolada, tornando a métrica mais robusta a ruídos pontuais.

Seleção de progenitores

A seleção de progenitores determina quais os indivíduos que contribuem geneticamente para a geração seguinte. Utilizamos um mecanismo de seleção conhecido como **Tournament Selection**, que seleciona k indivíduos aleatoriamente e retorna o melhor do grupo. O parâmetro $k=20$ foi escolhido heurísticamente: representa 20% da população, exercendo pressão seletiva moderada sem eliminar prematuramente soluções diversas.

Também utilizamos um mecanismo de seleção conhecido como **Roulette Wheel Selection** (seleção por roleta), que atribui a cada indivíduo uma probabilidade de seleção proporcional ao seu fitness relativo na população.

Cruzamento

O cruzamento (crossover) é o operador responsável por combinar o material genético de dois progenitores para gerar um ou mais descendentes. O objetivo é herdar características vantajosas de ambos os pais, promovendo a exploração de novas regiões do espaço de busca. Foram implementados e testados dois operadores de cruzamento, permitindo comparar o seu impacto no desempenho do algoritmo evolucionário, Two-Point Crossover e Uniform Crossover.

Operadores não utilizados

O operador Arithmetic Crossover foi considerado mas descartado após testes preliminares. Este operador gera um descendente cujos genes são combinações lineares convexas dos genes dos progenitores ($\text{gene} = \alpha \cdot g_1 + (1-\alpha) \cdot g_2$). Esta homogeneização prematura do genoma leva à perda de diversidade genética na população, dificultando a exploração de regiões distintas do espaço de busca. No contexto deste trabalho com populações de dimensão reduzida (100 indivíduos), este efeito é particularmente

prejudicial, já que a diversidade inicial é baixa e o operador não introduz variabilidade nova.

O operador Subtree Swap Crossover, tipicamente associado à Programação Genética, também não foi utilizado. Este operador pressupõe que o genótipo tem uma estrutura em árvore, permitindo trocar subárvores inteiras entre progenitores. No presente trabalho, a representação adotada é um vetor de números reais de dimensão fixa, portanto não faria sentido o seu uso.

Mutação

A mutação introduz variação aleatória nos genótipos dos descendentes, permitindo explorar regiões do espaço de busca não acessíveis pelo cruzamento. Implementou-se a mutação gaussiana:

- Com probabilidade `PROB_MUTATION` (por gene), adiciona ruído gaussiano ao valor do gene;

Também implementou-se a mutação uniforme:

- Com probabilidade `PROB_MUTATION` (por gene), adiciona um valor amostrado de uma distribuição uniforme no intervalo $[-STD_DEV, +STD_DEV]$ ao valor atual do gene, garantindo que o resultado permanece em $[-1, 1]$;

Os valores de `PROB_MUTATION` testados são 0.008 ($\approx 1/GENOTYPE_SIZE$, mutação mínima recomendada) e 0.05 ($\approx 5/GENOTYPE_SIZE$, mutação mais agressiva), conforme definido na tabela de experiências.

Operadores de mutação não utilizados

A mutação binária (Bit Flip Mutation) e a mutação baseada em árvore (Tree-Based Mutation) não foram utilizadas neste trabalho por serem incompatíveis com a representação adotada

Experiências a Realizar

Serão realizadas 8 configurações de experiências, cada uma com 5 execuções independentes (com sementes distintas para o gerador de números aleatórios), totalizando 40 execuções. A tabela seguinte resume as combinações de parâmetros:

Exp.	Mutação	Crossover	Elitismo	Pop. / Gerações	Execuções
1	0.008	0.5	0	100 / 100	5
2	0.05	0.5	0	100 / 100	5
3	0.008	0.9	0	100 / 100	5
4	0.05	0.9	0	100 / 100	5
5	0.008	0.5	1	100 / 100	5
6	0.05	0.5	1	100 / 100	5
7	0.008	0.9	1	100 / 100	5
8	0.05	0.9	1	100 / 100	5

Tabela 2: *Espaço de testes*

As principais hipóteses a testar com estas experiências são:

- Efeito da taxa de mutação: uma taxa mais elevada (0.05) introduz maior perturbação, podendo favorecer a exploração, mas dificultando a convergência;
- Efeito da probabilidade de crossover: uma probabilidade de crossover mais elevada (0.9) aumenta a recombinação, podendo acelerar a partilha de bons blocos genéticos;
- Efeito do elitismo: preservar o melhor indivíduo (ELITE_SIZE=1) evita regressão, mas pode reduzir a pressão para explorar novas regiões.

Para cada gráfico apresentado na análise de resultados, as execuções correspondem às 8 experiências definidas na tabela anterior, sendo que cada uma delas é executada com uma combinação diferente de funções de *parent selection*, *crossover* e *mutation*. As combinações utilizadas em cada experiência estão detalhadas na tabela seguinte:

#	Parent Selection	Crossover	Mutation
1	tournament_selection	Two_point_Crossover	gaussian_mutation
2	tournament_selection	Two_point_Crossover	uniform_mutation
3	tournament_selection	uniform_crossover	gaussian_mutation
4	tournament_selection	uniform_crossover	uniform_mutation
5	roulette_wheel_selection	Two_point_Crossover	gaussian_mutation
6	roulette_wheel_selection	Two_point_Crossover	uniform_mutation
7	roulette_wheel_selection	uniform_crossover	gaussian_mutation
8	roulette_wheel_selection	uniform_crossover	uniform_mutation

Tabela 3: Combinações de operadores por experiência

Métricas de Avaliação

Para cada experiência, as seguintes métricas são recolhidas e analisadas:

Métrica	Descrição
Fitness médio (1000 episódios)	Média da função objetivo sobre 1000 episódios de teste
Taxa de sucesso	Proporção de aterragens bem-sucedidas (check_successful_landing)
Melhor fitness por geração	Evolução do melhor indivíduo ao longo das gerações
Convergência	Número de gerações até estabilização do fitness

Tabela 4: Espaço de métricas

Os melhores indivíduos de cada execução (último registro de cada ficheiro de log) são testados em 1000 episódios sem seed fixa, permitindo estimar o fitness médio e a taxa de sucesso de forma robusta.

Análise de Resultados

Os gráficos seguintes apresentam a evolução do fitness médio ao longo das 100 gerações, para as 8 configurações experimentais testadas. Os gráficos estão organizados por função

de seleção de progenitores e, dentro de cada grupo, por combinação de operadores de crossover e mutação. A banda sombreada representa o desvio padrão entre as 5 execuções independentes de cada experiência, sendo o valor de referência (fitness ideal = 0) indicado a vermelho.

Grupo 1: Tournament Selection

As figuras a seguir apresentam os resultados das 8 experiências com seleção por torneio (k=20). Esta estratégia de seleção exerceu pressão seletiva moderada e consistente, favorecendo a convergência rápida nas primeiras gerações.




Figura 1




Figura 2




Figura 3




Figura 4

Grupo 2: Roulette Wheel Selection

As figuras a seguir mostram os resultados com sele  o por roleta. Comparativamente ao torneio, este m  todo apresentou converg  ncia mais lenta e maior variabilidade entre execu  es, resultante da press  o seletiva proporcional ao fitness relativo.




Figura 5




Figura 6




Figura 7




Figura 8

Análise por Parâmetro

Probabilidade de Mutação

O efeito da taxa de mutação foi um dos fatores mais determinantes nos resultados obtidos. A configuração com taxa elevada ($\text{mut}=0.05$) superou consistentemente a taxa baixa ($\text{mut}=0.008$) em praticamente todos os cenários testados. Com tournament selection e Two-point Crossover, a mutação gaussiana com $\text{mut}=0.05$ (Exp2) alcançou uma taxa de sucesso de 81.8%, contra apenas 5.6% da Exp1 com $\text{mut}=0.008$. Este contraste acentuado sugere que, com uma população de apenas 100 indivíduos e genótipos de dimensão reduzida (120 genes), $\text{mut}=0.008$ é insuficiente para escapar de ótimos locais. A taxa de 0.05 introduz perturbação suficiente para manter diversidade sem destruir estruturas genéticas já formadas.

Probabilidade de Crossover

O impacto da probabilidade de crossover foi menos uniforme e depende fortemente do tipo de crossover utilizado. Com Two-point Crossover, a probabilidade de 0.5 produziu melhores resultados do que 0.9 na maioria das configurações, especialmente com tournament selection (Exp2 com 81.8% vs Exp4 com 70.3%). Um crossover demasiado frequente destrói blocos funcionais de pesos sem garantia de gerar descendentes

melhores. Já com Uniform Crossover, a probabilidade de 0.9 tendeu a apresentar melhores resultados com tournament selection (Exp3: 37.2% e Exp7: 54.0%), pois a mistura gene a gene atenua o efeito destrutivo de recombinar segmentos inteiros.

Elitismo

O elitismo (ELITE_SIZE=1) revelou um comportamento ambivalente: em alguns cenários melhorou o desempenho, noutros prejudicou-o. Com tournament selection e mutação gaussiana de alta taxa, o elitismo reduziu a taxa de sucesso de 81.8% (Exp2, sem elite) para 51.6% (Exp6, com elite), sugerindo que a preservação do melhor indivíduo pode criar convergência prematura ao reduzir a pressão para explorar novas regiões.

Função de Seleção de Parentes

A tournament selection (k=20) apresentou superioridade clara sobre a roulette wheel selection na generalidade dos cenários, com convergência mais rápida e valores finais de fitness mais elevados. A roulette wheel selection, embora mais flexível em termos de pressão seletiva, mostrou maior variabilidade entre execuções e convergência mais lenta, em especial nas primeiras 40 gerações. Em alguns casos, como com Uniform Crossover e Gaussian Mutation, o fitness continuou a melhorar de forma gradual até à geração 100, sugerindo que a roulette wheel selection pode ainda não ter atingido a convergência completa nesse intervalo, ao contrário da tournament selection que estabiliza tipicamente entre as gerações 20 e 40.

Tipo de Crossover

A comparação entre Two-point Crossover e Uniform Crossover não produziu um vencedor absoluto, dependendo fortemente da função de seleção e da taxa de mutação. Com tournament selection e mutação gaussiana alta, o Two-point Crossover com cross=0.5 obteve o melhor resultado individual (81.8%, Exp2), enquanto o Uniform Crossover com cross=0.9 e elite atingiu 83.3% (Exp8). Com roulette wheel selection, o Two-point Crossover com mutação gaussiana mostrou taxas de sucesso mais consistentes (até 69.3%), sendo menos sensível à escolha da probabilidade de crossover do que o Uniform Crossover.

Tipo de Mutação

A mutação gaussiana superou a mutação uniforme na grande maioria das configurações. Com tournament selection e Two-point Crossover, a mutação gaussiana com $\text{mut}=0.05$ alcançou 81.8% de taxa de sucesso (Exp2), enquanto a mutação uniforme com os mesmos parâmetros obteve apenas 37.2%. Esta diferença explica-se pela natureza das perturbações: a mutação gaussiana introduz ruído calibrado pelo desvio padrão, preservando a escala dos pesos e explorando gradualmente o espaço de soluções, ao passo que a mutação uniforme aplica deslocamentos aleatórios de amplitude fixa, menos adequados à estrutura contínua do espaço de pesos de redes neurais.

Conclusão da Análise

A combinação com melhor taxa de acerto global foi a Experiência 8 (Exp8): tournament selection ($k=20$), Uniform Crossover com $\text{cross}=0.9$, mutação gaussiana com $\text{mut}=0.05$ e elitismo ativo ($\text{ELITE_SIZE}=1$), que atingiu uma taxa de sucesso de 83.3%. Esta configuração beneficiou da complementaridade entre o Uniform Crossover — que ao misturar gene a gene atenua o efeito destrutivo sobre blocos funcionais — e a mutação gaussiana de alta taxa, que mantém diversidade suficiente para que o elitismo não induza convergência prematura. A segunda melhor configuração foi a Exp2 (tournament selection, Two-point Crossover com $\text{cross}=0.5$, mutação gaussiana com $\text{mut}=0.05$, sem elitismo), com 81.8% de taxa de sucesso, confirmando que a tournament selection e a mutação gaussiana elevada são os fatores mais determinantes para o desempenho. Em geral, as principais conclusões são que a taxa de mutação é o fator de maior impacto, sendo 0.05 claramente superior a 0.008 para este problema; a tournament selection converge mais rápido e de forma mais estável do que a roulette wheel selection; o elitismo é benéfico apenas quando combinado com operadores que mantenham diversidade suficiente; e a mutação gaussiana é mais adequada do que a uniforme para a otimização de pesos de redes neurais devido à sua natureza de perturbação gradual.

Otimizações para o ambiente com presença de vento

Para a resolução do desafio da meta 2 que introduz o vento ao lunar lander, deve-se considerar a aleatoriedade introduzida pelo vento, ou seja, a nave não pode aprender um caminho específico para a realização do pouso. Portanto, o genótipo do melhor indivíduo

deve incluir uma variedade de blocos funcionais que permitam a nave se adaptar a qualquer situação.

Com a introdução do vento, pode-se observar na figura abaixo que houve uma queda significativa de taxa de sucesso numa das melhores combinações de parâmetros e operadores.




Figura 9

Para a resolução deste problema, foram feitas algumas alterações no código que implementava a solução sem vento:

Duplicação da hidden layer

Com vento e turbulência, o agente precisa de aprender políticas de controlo mais complexas — por exemplo, compensar simultaneamente o desvio horizontal causado pelo vento (x , v_x), a instabilidade angular causada pela turbulência (θ , v_θ), e ainda controlar a descida vertical (v_y). Uma única camada de 12 neurónios pode não ter capacidade representacional suficiente para capturar estas interdependências. Ao aumentar para 24 neurónios, aumenta-se a capacidade da rede para aprender mapeamentos mais complexos entre o estado do ambiente e a ação dos motores, à custa de um espaço de busca maior (genótipo de 240 genes em vez de 120), o que pode exigir mais gerações para convergir.

Aumento do número de gerações

Tendo em vista a alteração mencionada no ponto anterior, o aumento do espaço de procura (de 120 para 240 genes) faz com que seja necessário um maior número de gerações para dar tempo ao algoritmo de explorar e convergir para regiões promissoras. Portanto, o número de gerações passou de 100 para 150. Note-se que este aumento representa um compromisso entre qualidade da solução e custo computacional — idealmente o número de gerações seria maior, mas 150 foi considerado suficiente dado o tempo disponível.

Alteração da “objective_function”

Com a introdução do vento, a nave sofre desvios horizontais significativamente maiores do que em ambiente sem vento. Uma vez que a função objetivo avalia as últimas observações do episódio, e esses desvios são agora mais frequentes e de maior magnitude, aumentou-se o peso da penalização da distância horizontal ao centro da plataforma de 100 para 150. Este valor foi escolhido após experimentação com os valores 125, 150 e 200, tendo 150 apresentado um melhor equilíbrio entre pressão seletiva sobre o desvio horizontal e a capacidade do agente de otimizar os restantes critérios de aterragem — valores mais altos como 200 tendiam a fazer com que o agente focasse exclusivamente em centrar horizontalmente, negligenciando o controlo da velocidade vertical e do ângulo.

Aumento da probabilidade de mutação

Com a introdução do vento, o espaço de soluções eficazes torna-se mais restrito — o agente precisa de aprender políticas de controlo mais robustas que compensem perturbações externas imprevisíveis. Para aumentar a capacidade de exploração do algoritmo nestas condições, aumentou-se a probabilidade de mutação de 0.05 para 0.1. Foram testados valores como 0.08, 0.1, 0.5 e observou-se que o que apresentava melhores resultados era o 0.1. Este aumento permite que o algoritmo explore regiões mais diversas do espaço de procura, aumentando a probabilidade de encontrar genótipos capazes de lidar com as adversidades impostas pelo vento.

Optou-se por aumentar a mutação em vez da probabilidade de crossover porque, em neuroevolução, os pesos de uma rede neuronal apresentam elevada epistasia — isto é, o efeito de um gene depende dos restantes. O crossover, ao recombinar segmentos de dois

genótipos distintos, tende a destruir blocos funcionais de pesos que em conjunto produziam um comportamento útil, sem garantia de que a recombinação produza algo melhor. A mutação gaussiana, por outro lado, introduz perturbações graduais que preservam a estrutura geral do genótipo enquanto exploram variações locais, sendo mais adequada para otimização em espaços de elevada epistasia como o das redes neuronais.

Média de 3 simulações

Para obter uma estimativa mais fiável do fitness de cada indivíduo, cada genótipo é avaliado em 3 simulações independentes, sendo o fitness final a média dos valores obtidos. Esta abordagem é particularmente importante na presença de vento, uma vez que a variabilidade entre episódios é significativamente maior do que em ambiente sem vento — o mesmo genótipo pode obter fitness muito diferentes dependendo da intensidade e direção do vento em cada episódio. Ao fazer a média de 3 simulações, reduz-se o impacto de avaliações ruidosas, evitando que indivíduos que tiveram sorte numa única simulação sejam incorretamente favorecidos pela seleção, e que indivíduos genuinamente bons sejam descartados por terem tido uma simulação desfavorável. Esta abordagem tem como custo triplicar o tempo de avaliação por indivíduo, o que foi considerado um compromisso aceitável face à melhoria na fiabilidade do processo evolutivo.

Assim obteve-se uma versão de lunar-lander capaz de aterrar na presença de vento, utilizando `uniform_crossover` em vez de `two_point crossover` e uma taxa de mutação de 10%.




Figura 10

Como se pode observar na figura anterior, com a implementação feita, conseguiu-se uma taxa de sucesso de 69%, mostrando uma melhora significativa comparadamente à figura 9 (implementação sem vento).

Com a introdução do vento, optou-se por desativar o elitismo ($ELITE_SIZE=0$). Em ambiente sem vento, a noção de "melhor indivíduo" é relativamente estável — o mesmo genótipo tende a produzir resultados consistentes entre episódios. Com vento, o fitness de um indivíduo varia significativamente entre episódios devido à aleatoriedade das condições de vento, tornando a noção de melhor indivíduo pouco fiável. Preservar um indivíduo com base num fitness potencialmente inflacionado por condições favoráveis de vento pode introduzir um viés na evolução, ocupando um slot da população com um indivíduo cuja qualidade real é incerta.

Adicionalmente, em neuroevolução com espaços de procura de elevada epistasia, o que importa não é preservar um único indivíduo, mas sim acumular blocos funcionais de pesos ao longo das gerações através dos operadores de variação. Sem elitismo, a população mantém maior diversidade genética, favorecendo a exploração de regiões do espaço de procura que permitam desenvolver políticas de controlo robustas face às adversidades impostas pelo vento.